

IMAGE ENHANCEMENT MENGGUNAKAN MULTI-HISTOGRAM EQUALIZATION BERBASIS HSV COLOR SPACE DENGAN SPATIAL-CONSTRAINED FUZZY C-MEANS

Adidya Abimanyu¹, Ayasha Anggun Anindya², Rasyid Muhammad Agha³
L0122004¹, L0122028², L0122135³
adidyaabimayu07@student.uns.ac.id¹, ayashaanindya@student.uns.ac.id²,
rasyidagha@student.uns.ac.id³

ABSTRAK

Peningkatan kualitas citra digital merupakan aspek penting dalam berbagai aplikasi seperti kesehatan, pengawasan, dan penginderaan jarak jauh. Metode klasik histogram equalization (HE) sering mengalami kelemahan seperti pergeseran kecerahan dan over-enhancement yang menyebabkan hilangnya detail. Penelitian ini mengembangkan metode image enhancement berbasis multi-histogram equalization dengan memanfaatkan Spatial-Constrained Fuzzy C-Means pada HSV color space untuk menghasilkan segmentasi hitogram yang lebih robust. Metode ini mengintegrasikan spatial constraint dengan bobot $\alpha = 0.85$ pada proses clustering FCM untuk meningkatkan robustness terhadap noise. Evaluasi dilakukan pada 6 dataset standar (Berkeley, CSIQ, Kodak, USC-SIPI, UCMerced, dan SRI-WHU) dengan total 5.064 citra menggunakan metrik SSIM, IE, AMBE, dan FSIM. Hasil eksperimen menunjukkan metode HSV Spatial FCM mengungguli baseline dengan peningkatan SSIM +2,35%, penurunan AMBE -14.66%, dan peningkatan FSIM +8.93%. Metode ini mencapai performa excellent dengan SSIM > 0.99 pada Kodak(0.9942) dan CSIQ (0.9951), serta menunjukkan konsistensi pada berbagai kategori brightness dengan range SSIM 0.8727-0.9951. Integrasi spatial constraint terbukti efektif meningkatkan structural preservation, brightness preservation, dan perceptual quality, menjadikan metode ini dapat digeneralisasi untuk berbagai aplikasi image enhancement.

Kata Kunci : Image Enhancement, Multi-Histogram Equalization, Spatial-Constrained Fuzzy C-Means, HSV Color Space, Brightness Preservation.

I. PENDAHULUAN

Perkembangan teknologi telah menyebabkan peningkatan dalam penggunaan citra sebagai media informasi di berbagai bidang, seperti kesehatan, pengawasan (*surveillance*), dan lain-lain [9]. Namun, citra yang dihasilkan sering kali mengalami penurunan kualitas, seperti kontras yang buruk, pencahayaan yang rendah, dan tingkat *noise* yang tinggi [9]. Kondisi ini menurunkan informasi yang terdapat pada citra, sehingga diperlukan suatu *image enhancement* untuk meningkatkan kualitasnya [8].

Salah satu metode klasik yang banyak digunakan untuk peningkatan kualitas citra adalah *histogram equalization* (HE). Metode ini bekerja dengan menyebarkan intensitas piksel secara merata pada rentang 0-255 agar rentang dinamis citra menjadi lebih lebar sehingga kontras meningkat [1]. Meskipun sederhana dan mudah diimplementasikan, HE konvensional memiliki

beberapa kelemahan utama, yaitu pergeseran kecerahan yang signifikan (*brightness shift*) dan *over-enhancement* pada region tertentu yang dapat menyebabkan hilangnya detail [8]. Untuk mengatasi masalah ini, [8] mengusulkan *Brightness Preserving Bi-Histogram Equalization* (BBHE) yang membagi histogram input menjadi dua sub-histogram berdasarkan *mean brightness*, kemudian melakukan *equalization* secara independen pada masing-masing bagian untuk mempertahankan *mean brightness* asli.

[1] membandingkan beberapa metode preservasi *brightness*, termasuk BBHE, *Dual Sub-Image Histogram Equalization* (DSIHE) yang menggunakan median sebagai threshold pembagian, dan *Minimum Mean Brightness Error Bi-Histogram Equalization* (MMBEBHE) yang mencari threshold optimal untuk meminimalkan Absolute Mean Brightness Error (AMBE). Hasil

eksperimen mereka menunjukkan bahwa DSIHE memberikan preservasi *brightness* yang lebih baik mengusulkan *Recursive Mean-Separate Histogram Equalization* (RMSHE) yang dapat membagi Pendekatan pembagian histogram kemudian dikembangkan menjadi *multi-histogram equalization* (MHE) yang lebih adaptif. [7] mengembangkan *Brightness Preserving Dynamic Histogram Equalization* (BPDHE) yang secara dinamis menentukan jumlah sub-histogram berdasarkan karakteristik distribusi intensitas citra untuk menghasilkan *enhancement* yang lebih natural. [10] mengusulkan *Brightness Preserving Bi-Histogram Equalization* using *Edge Pixels* yang memanfaatkan informasi tepi untuk meningkatkan kualitas *enhancement*. [9] lebih lanjut mengembangkan metode MHE yang memanfaatkan *Kernel Density Estimation* (KDE) untuk menganalisis distribusi histogram dan menentukan jumlah kluster secara adaptif.

[9] mengusulkan metode MHE yang memanfaatkan *Kernel Density Estimation* (KDE) untuk menganalisis distribusi histogram, kemudian menerapkan *Fuzzy C-Means* (FCM) *clustering* untuk membagi histogram secara adaptif. Metode ini juga mengintegrasikan strategi *optimized clipping and redistribution* dengan penyesuaian parameter untuk mengontrol tingkat *enhancement* sambil mempertahankan detail citra. Eksperimen pada dataset Kodak, CSIQ, dan Berkeley menunjukkan bahwa metode tersebut mengungguli sepuluh algoritma HE state-of-the-art dengan nilai rata-rata SSIM 0.9647, IE 7.5268, AMBE 3.5431, dan FSIM 0.9063.

Namun, FCM standar memiliki keterbatasan dalam hal *robustness* terhadap *noise* dan tidak mempertimbangkan informasi spasial antar piksel dalam proses klustering [9]. [2] mengusulkan modifikasi FCM yang mengintegrasikan *spatial constraint* untuk meningkatkan *robustness* dalam aplikasi segmentasi citra medis. Pendekatan berbasis *spatial constraint* telah terbukti dapat meningkatkan stabilitas hasil klustering pada citra dengan *noise* atau tekstur kompleks [11]. Integrasi informasi *neighborhood spatial* diharapkan dapat menghasilkan segmentasi histogram yang lebih smooth dan mengurangi sensitivitas terhadap *local fluctuations* pada distribusi intensitas citra [9].

Untuk memastikan generalisasi metode *enhancement*, evaluasi pada *multiple standard* beberapa dataset seperti Berkeley, CSIQ, Kodak,

dibandingkan BBHE pada sebagian besar test images. Selain itu, [1] juga

histogram secara rekursif hingga level tertentu untuk kontrol *brightness* yang lebih fleksibel.

dan USC-SIPI telah menjadi praktik umum dalam penelitian image enhancement. Metrik kuantitatif yang sering digunakan meliputi *Structural Similarity Index* (SSIM) untuk mengukur *similarity* struktural, *Average Mean Brightness Error* (AMBE) untuk preservasi *brightness*, *Information Entropy* (IE) untuk mengukur content information, dan *Feature Similarity Index Measure* (FSIM) untuk *perceptual quality*.

Berdasarkan tinjauan literatur di atas, meskipun metode berbasis FCM telah menunjukkan hasil yang baik dalam *adaptive histogram segmentation*, beberapa penelitian menunjukkan bahwa FCM standar cenderung sensitif terhadap *noise* dan *local fluctuations* karena tidak mempertimbangkan informasi spasial antar piksel [2, 11]. Integrasi *spatial constraint* ke dalam FCM *clustering* telah terbukti dapat meningkatkan *robustness* dalam aplikasi segmentasi citra, namun penerapannya pada konteks *multi-histogram equalization* untuk *image enhancement* masih perlu dieksplorasi lebih lanjut. Oleh karena itu, penelitian ini bertujuan mengembangkan metode *image enhancement* berbasis *multi-histogram equalization* yang memanfaatkan *Spatial-Constrained Fuzzy C-Means* untuk menghasilkan segmentasi histogram yang lebih robust, preservasi *brightness* yang baik, dan kualitas *enhancement* yang konsisten pada berbagai jenis citra. Metode yang dikembangkan akan dievaluasi secara komprehensif menggunakan dataset Berkeley, CSIQ, Kodak, SIRI-WHU, UCMerced, dan USC-SIPI untuk memastikan generalisasi performa pada beragam karakteristik citra.


II. STUDI PUSTAKA

2.1 Pengolahan Citra Digital

Pengolahan citra digital merupakan proses manipulasi dan analisis citra menggunakan komputer untuk meningkatkan kualitas visual atau mengekstraksi informasi penting dari citra [6]. Citra digital direpresentasikan sebagai matriks piksel dengan nilai intensitas yang menggambarkan tingkat kecerahan pada setiap titik.

2.2 Image Enhancement

Image enhancement (peningkatan kualitas citra) adalah metode yang digunakan untuk meningkatkan kualitas citra dengan meningkatkan detail, kontras, dan ketajaman warna [4]. Metode ini biasa digunakan dalam berbagai bidang seperti deteksi objek, medis, dan pemrosesan video. Tujuan utama dari *image enhancement* adalah membuat citra lebih sesuai untuk pemakaian tertentu dengan meningkatkan detail dan fitur-fitur penting. Secara sederhana, proses *image enhancement* dapat dilihat pada ilustrasi di bawah:



Gambar 2.1: Ilustrasi Image Enhancement

Gambar 2.1 sebagai *input* awal citra yang memiliki tingkat kontras lebih rendah, sedangkan gambar di sebelah kanan merupakan *output* citra yang memiliki tingkat kontras dan detail lebih baik dibandingkan dengan *input* awal.

2.3 Histogram Equalization (HE)

Histogram equalization adalah salah satu metode yang paling banyak digunakan untuk meningkatkan kontras citra. Cara kerja HE adalah meratakan intensitas piksel melalui transformasi fungsi intensitas sehingga histogram suatu citra mendekati distribusi yang sejenis. HE bertujuan untuk memodifikasi histogram sehingga seluruh intensitas dapat dimanfaatkan secara optimal untuk meningkatkan kontras citra [12]. HE memanfaatkan fungsi *cumulative distribution function* dari histogram citra *grayscale* (hitam putih). Transformasi ini dilakukan dengan memetakan intensitas lama ke intensitas baru menggunakan formula (1):

$$s = T(r) = (L - 1) \cdot CDF(r) \quad (1)$$

Dengan:

r = intensitas input

s = intensitas output

L = jumlah level intensitas

$CDF(r)$ = fungsi distributif kumulatif dari histogram citra

Metode ini efektif meningkatkan kontras citra dengan distribusi intensitas yang menumpuk pada rentang tertentu.

2.4 Multi-Histogram Equalization (MHE)

Multi-Histogram Equalization (MHE) Adalah perkembangan dari metode HE konvensional dengan tujuan mengatasi kelemahan metode HE konvensional. Salah satu perubahannya adalah pada *brightness*, *over-enhancement*, ketika histogram intensitas citra memiliki distribusi kompleks atau multimodal [1].

Pada MHE, histogram akan dibagi terlebih dahulu menjadi beberapa bagian berdasarkan tingkat intensitas atau fitur tertentu. Kemudian setiap bagian tersebut di-*equalize* secara independen. Dengan cara ini, dapat meningkatkan kontras secara spesifik/lokal ke bagian-bagian intensitas berbeda, sehingga visual citra yang dihasilkan seimbang dan detail yang lebih terjaga.

2.5 Algoritma Spatially Constrained FCM

Spatially Constrained Fuzzy C-Means (SFCM) adalah perkembangan dari algoritma *Fuzzy C-Means* yang menambahkan *spatial information* dari piksel tetangga ke dalam proses *clustering*. [3]. Dengan tujuan menghasilkan citra yang tahan *noise*, dan lebih sesuai struktur citra, terutama pada citra yang memiliki *noise* tinggi.

SFCM menambahkan *spatial information term* ke dalam fungsi objektif FCM. Informasi ini berasal dari piksel tetangga. Penambahan komponen *spatial* bertujuan mengurangi efek *noise*, membuat citra lebih halus, dan piksel memiliki *cluster membership* yang mirip dengan tetangganya. Rumus dasar SFCM didefinisikan di formula (2):

$$J = \sum_{i=1}^N \sum_{j=1}^C u_{ij}^m \|x_i - v_j\|^2 + \lambda \sum_{i=1}^N \sum_{j=1}^C u_{ij}^m S_{ij} \quad (2)$$

Di mana:

u_{ij} = derajat keanggotaan fuzzy piksel ke- i pada cluster ke- j

v_j = pusat cluster

S_{ij} = pengaruh tetangga

λ = parameter seberapa kuat informasi spasial yang diinginkan

m = fuzziness parameter


2.6 Color Spatial

Color Spatial mengacu pada penggabungan *color information* dan *spatial information* suatu piksel dalam proses pengolahan citra, khususnya pada segmentasi atau *enhancement* [5]. Artinya, setiap piksel direpresentasikan bukan hanya berdasarkan

unit warnanya (RGB, HSV, LAB, dll) tapi juga posisi piksel tersebut dalam ruang spasial (koordinat tetangga).

III. METODOLOGI PENELITIAN

Metodologi yang dilakukan pada penelitian ini ditunjukkan oleh Gambar 3.1. Penelitian ini terdiri dari 1) Pengumpulan Dataset 2) *Preprocessing Dataset* 3) Pembangunan Metode *Enhancement* 4) Proses *Enhancement* 5) Evaluasi & Analisis



Gambar 3.1: Alur Program

3.1 Pengumpulan Dataset

Penelitian ini menggunakan empat dataset standar yang umum digunakan dalam evaluasi algoritma *image enhancement* untuk memastikan generalisasi metode yang dikembangkan. Dataset yang digunakan meliputi:

3.1.1. Dataset Berkeley (BSDS300)

- Jumlah citra: 300 citra
- Karakteristik: Natural images dengan kompleksitas tekstur tinggi
- Sumber: Berkeley Segmentation Dataset

3.1.2. Dataset CSIQ

- Jumlah citra: 30 reference images
- Karakteristik: Image quality assessment dataset
- Sumber: CSIQ Image Database

3.1.3. Dataset Kodak

- Jumlah citra: 24 citra PhotoCD
- Karakteristik: High-quality color images dengan berbagai scene
- Sumber: Kodak Image Dataset

3.1.4. Dataset USC-SIPI

- Jumlah citra: 210
- Karakteristik: Miscellaneous images (textures, aerials, sequences)
- Sumber: USC-SIPI Image Database

Penelitian ini juga menambahkan dua dataset tambahan guna untuk *cross validation* dan datasetnya sebagai berikut:

3.1.5. Dataset UCMerced Land Use

- Jumlah citra: 2.100
- Karakteristik: Aerial/satellite imagery, 21 land-use categories
- Sumber: UC Merced Land Use Dataset

3.1.6. Dataset SIRI-WHU

- Jumlah citra: 2.400 citra
- Karakteristik: Remote sensing images dengan variasi brightness tinggi
- Sumber: SIRI-WHU database

3.2 Preprocessing Dataset

Tahap preprocessing dilakukan untuk mempersiapkan dataset sebelum proses enhancement. Langkah-langkah yang dilakukan meliputi:

3.2.1. Konversi Color Space

- Input: RGB color image

- Konversi: BGR (OpenCV format) → HSV color space

3.2.2. Ekstraksi V Channel

- V channel (Value/Brightness) diekstraksi dari HSV representation
- Range intensitas: 0-255
- V channel menjadi input untuk algoritma enhancement

3.2.3. Validasi Data

- Pengecekan ukuran citra minimum (untuk memastikan kompatibilitas spatial filtering)
- Validasi format file

3.3 Pembangunan Metode

Penelitian ini mengembangkan dua metode enhancement berbasis multi-histogram equalization untuk dilakukan perbandingan performa: (1) Standard FCM-based MHE sebagai baseline, dan (2) Spatial-Constrained FCM-based MHE sebagai metode yang diusulkan.

3.1.1. Base Model: Multi-Histogram Equalization Framework

Framework dasar yang digunakan mengadopsi pendekatan [9] dengan modifikasi pada tahap clustering. Arsitektur framework terdiri dari beberapa komponen utama yang saling terintegrasi:

A. Kernel Density Estimation (KDE)

Tahap pertama adalah analisis distribusi histogram menggunakan Kernel Density Estimation untuk menghasilkan estimasi probabilitas yang smooth. KDE diterapkan pada histogram citra dengan formula (3).

$$f(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (3)$$

dimana $K(u)$ adalah Gaussian kernel function didefinisikan di formula (4).

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \quad (4)$$

Implementasi KDE menggunakan parameter bandwidth $h = 5$ dengan kernel size $6h = 30$ pixels. Hasil konvolusi histogram

dengan Gaussian kernel dinormalisasi untuk menghasilkan probability density estimation.

B. Smoothing dan Peak Detection

KDE curve di-smooth menggunakan Gaussian filter untuk mengeliminasi noise dan local fluctuations didefinisikan di formula (5).

$$f_{smooth}(x) = \text{GaussianFilter}(f(x), \sigma = 3) \quad (5)$$

Peak detection dilakukan pada smoothed KDE menggunakan algoritma find_peaks dari SciPy dengan minimum distance constraint di formula (6).

$$d_{min} = \max\left(1, \left\lfloor \frac{\sigma_{brightness}}{2} \right\rfloor\right) \quad (6)$$

dimana $\sigma_{brightness}$ adalah standar deviasi brightness citra. Jumlah peaks yang terdeteksi (c) menjadi jumlah cluster adaptif, dan nilai intensitas pada posisi peaks menjadi initial cluster centers v_1, v_2, \dots, v_c .

C. Histogram Segmentation

Setelah clustering, histogram dibagi menjadi sub-histograms berdasarkan cluster assignment. Untuk setiap cluster, range intensitas ditentukan di formula (7).

$$[mink, maxk] = [\min(z_i | label_i = k), \max(z_i | label_i = k)] \quad (7)$$

Sub-histogram H_k dihitung dengan binning pixels dalam range tersebut menggunakan np.bincount.

D. Optimized Clipping & Redistribution

Plateau limit untuk setiap sub-histogram dihitung sebagai rata-rata dari mean dan median di formula (8).

$$T_k = \frac{\mu_k + m_k}{2} \quad (8)$$

dimana μ_k adalah mean brightness dan m_k adalah median brightness dari sub-histogram H_k .

Clipping dilakukan dengan membatasi nilai histogram seperti di formula (9).

$$H'_k(i) = \min(H_k(i), T_k) \quad (9)$$

Redistribution value dihitung berdasarkan jumlah pixels yang di-clip seperti di formula (10).

$$R_k = k \cdot \frac{\sum_i \max(H_k(i) - T_k, 0)}{\text{span}_k} \quad (10)$$

dimana $k = 0.5$ adalah redistribution parameter $\text{span}_x = \max_k - \min_k + 1$.

E. Dynamic Range Allocation

Dynamic range untuk setiap sub-histogram dialokasikan secara proporsional berdasarkan span dan jumlah pixels di formula (11).

$$DR_k = \left\lfloor \frac{\text{span}_k \cdot \ln(N_k + 1)}{\sum_{j=1}^c \text{span}_j \cdot \ln(N_j + 1)} \times 255 \right\rfloor \quad (11)$$

dimana $N_k = \sum_i H''_k(i)$ adalah total pixels dalam sub-histogram k .

F. Histogram Equalization

Transfer function dihitung berdasarkan cumulative distribution function (CDF) dari redistributed histogram di formula (12) dan (13).

$$PDF_k(i) = \frac{H''_k(i)}{N_k} \quad (12)$$

$$CDF_k(i) = \sum_{j=0}^i PDF_k(j) \quad (13)$$

Mapping function untuk setiap sub-histogram didefinisikan di formula (14).

$$T_k(i) = DR_k \cdot CDF_k(i) \cdot 1_{[k=1]} + \left(R_{start}^{(k)} + 1 + (DR_k - 1) \cdot CDF_k(i) \right) \cdot 1_{[k>1]} \quad (14)$$

dimana $R_{start}^{(k)} = \sum_{j=1}^{k-1} DR_j$ adalah cumulative starting range.

3.1.2. Method 1: Standard Fuzzy C-Means Clustering (Baseline)

Metode baseline menggunakan Standard Fuzzy C-Means (FCM) untuk clustering brightness pixels. FCM adalah algoritma clustering fuzzy yang memungkinkan setiap pixel memiliki membership degree terhadap multiple clusters.

Langkah 1: Initialization

Cluster centers diinisialisasi dari peak positions yang terdeteksi pada tahap KDE seperti pada formula (15).

$$V^{(0)} = [v_1, v_2, \dots, v_c]^T \quad (15)$$

dimana V_k adalah intensitas pada peak ke- k .

Langkah 2: Membership Calculation

Untuk setiap pixel dan cluster, hitung distance di formula (16).

$$d_{ik} = |x_i - v_k| \quad (16)$$

Membership degree dihitung menggunakan formula FCM standard seperti di formula (17).

$$u_{ik} = \frac{1}{\sum_{j=1}^c \left(\frac{d_{ik}}{d_{ij}} \right)^{\frac{2}{m-1}}} \quad (17)$$

dimana $m = 2$ adalah fuzziness parameter. Untuk menghindari division by zero, minimum distance di-set ke 10^{-10} .

Normalisasi dilakukan untuk memastikan $\sum_{k=1}^c u_{ik} = 1$ seperti di formula (18).

$$u_{ik} \leftarrow \frac{u_{ik}}{\sum_{j=1}^c u_{ij}} \quad (18)$$

Langkah 3: Cluster Center Update

Update cluster centers berdasarkan weighted membership didefinisikan di formula (19).

$$v_k^{(t+1)} = \frac{\sum_{i=1}^m u_{ik}^m \cdot x_i}{\sum_{i=1}^m u_{ik}^m} \quad (19)$$

Langkah 4: Convergence Check

Iterasi dihentikan jika perubahan clusters centers kurang dari threshold dan didefinisikan di formula (20).

$$\|V^{(t+1)} - V^{(t)}\| < \epsilon = 10^{-5} \quad (20)$$

Atau jika mencapai iterasi maksimum

Langkah 5: Hard Assignment

Setelah konvergensi, setiap pixel di-assign ke cluster dengan membership tertinggi dan didefinisikan di formula (21).

$$label_i = \arg \min_k d_{ik} \quad (21)$$

3.1.3. Method 2: Spatial-Constrained Fuzzy C-Means Clustering (Proposed)

Modifikasi utama pada metode yang diusulkan adalah penambahan spatial constraint pada tahap clustering sebagaimana digambarkan pada Gambar 3.2 untuk meningkatkan robustness terhadap noise dan local fluctuations.

Langkah 1-2: Standard Membership Calculation

Sama dengan Standard FCM (Section 3.3.2, Langkah 1-2).

Langkah 3: Spatial Filtering (MODIFIKASI UTAMA)

Membership matrix di-reshape ke spatial domain sesuai dimensi citra, seperti di formula (22).

$$U_{img} = \text{reshape}(U, [h, w, c]) \quad (22)$$

Untuk setiap cluster, spatial membership dihitung menggunakan 3×3 averaging kernel seperti di formula (23).

$$\bar{u}_{pq}^k = \frac{1}{9} \sum_{(i,j) \in N_{3 \times 3}(p,q)} u_{ij}^{(k)} \quad (23)$$

Dimana $N_{3 \times 3}(p, q)$ adalah 3×3 neighborhood centered at pixel (p, q) . Implementasi menggunakan cv2.filter2D dengan kernel uniform $\frac{1}{9} \mathbf{1}_{3 \times 3}$.

Langkah 4: Weighted Combination (MODIFIKASI)

Standard membership dan spatial membership dikombinasikan dengan weighted average seperti di formula (24).

$$u'_{ik} = \alpha \cdot u_{ik} + (1 - \alpha) \cdot \bar{u}_{ik} \quad (24)$$

dimana $\alpha = 0.85$ adalah spatial constraint weight. Nilai α yang tinggi (0.85) mempertahankan informasi intensitas individual pixels, sementara komponen $(1 - \alpha) = 0.15$ menambahkan spatial smoothness dari neighborhood.

Langkah 5: Normalization

Normalized membership untuk memastikan sum-to-one constraint di formula (25).

$$u'_{ik} = \frac{u'_{ik}}{\sum_{j=1}^c u'_{ij}} \quad (25)$$

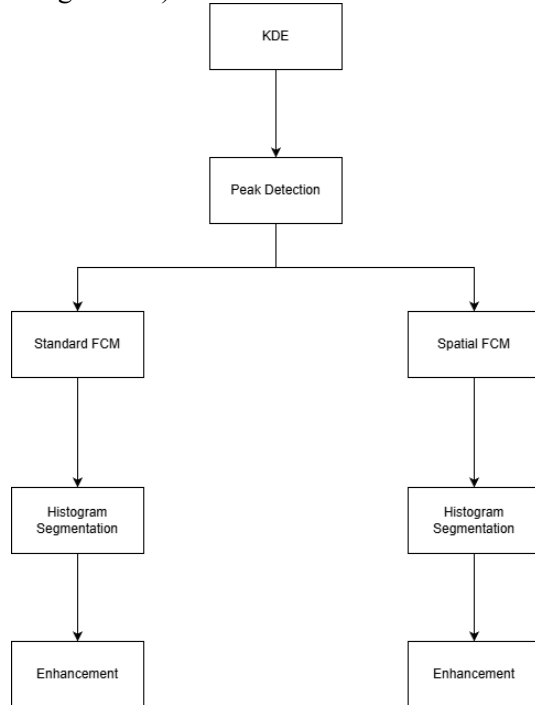
Langkah 6: Cluster Center Update

Update cluster centers menggunakan spatially-constrained membership seperti di formula (26).

$$v_k^{(t+1)} = \frac{\sum_{i=1}^n (u'_{ik})^m \cdot x_i}{\sum_{i=1}^n (u'_{ik})^m} \quad (26)$$

Langkah 7: Convergence Check dan Hard Assignment

Sama dengan Standard FCM (Section 3.3.2, Langkah 4-5).



Gambar 3.2: Alur Program Dalam Menguji 2 Model

3.4 HyperParameter Setting

Parameter yang digunakan dalam penelitian ini.

Tabel 1: HyperParameter Setting

| Parameter | Nilai |
|-------------------------|-------|
| Fuzziness parameter (m) | 2 |

| | |
|--------------------------------------|--------------------|
| Spatial weight (α) | 0.85 |
| Clipping parameter (k) | 0.5 |
| Convergence threshold (ϵ) | 1×10^{-5} |
| Max iterations | 100 |
| KDE bandwidth (h) | 5 |
| Smoothing sigma | 3 |

3.5 Proses Enhancement

Alur Proses

1. Load RGB image dari dataset
2. Konversi BGR menjadi HSV color space
3. Ekstrak V channel (kecerahan)
4. Apply enhancement
5. Dapatkan *enhanced* V channel
6. *Replace* V channel original dengan *enhanced* V
7. Konversi HSV menjadi BGR
8. Save enhanced image

3.6 Evaluasi Model

A. Structural Similarity Index

Mengukur similarity struktural antara citra original dan enhanced seperti di formula (27).

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (27)$$

- Range: 0-1 (semakin tinggi semakin baik)
- Interpretasi: $SSIM > 0.9$ = excellent quality preservation

B. Information Entropy (IE)

Mengukur content information dalam enhanced image seperti di formula (28).

$$IE = - \sum_{i=0}^{255} p(i) \log_2 p(i) \quad (28)$$

dimana $p(i)$ = probability dari intensity level i .

- Range: 0-8 bits (semakin tinggi semakin baik)

- Interpretasi: $IE > 7.0$ = rich information content

C. Absolute Mean Brightness Error (AMBE)

Mengukur preservasi brightness pada formula (29).

$$AMBE = |\overline{x_{original}} - \overline{x_{enhanced}}| \quad (29)$$

- Range: 0-255 (semakin rendah semakin baik)
- Interpretasi: $AMBE < 5.0$ = excellent brightness preservation

D. Feature Similarity Index Measure (FSIM)

Mengukur perceptual quality berbasis phase congruency dan gradient seperti di formula (30).

$$FSIM = \frac{\sum_{x \in \Omega} S_L(x) \cdot PC_m(x)}{\sum_{x \in \Omega} PC_m(x)} \quad (30)$$

dimana S_L = local similarity, = maximum phase congruency.

- Range: 0-1 (semakin tinggi semakin baik)
- Interpretasi: $FSIM > 0.85$ = excellent perceptual quality

3.7 Analisis Komparatif

A. Perbandingan Metode

- Standard FCM-MHE vs Spatial FCM-MHE (Proposed)
- Perhitungan rata-rata metrik per dataset

B. Analisis Per-Dataset

- Evaluasi performa pada setiap dataset
- Identifikasi dataset yang challenging

C. Analisis Per-Brightness Category

- Dark images (mean brightness < 85)
- Normal images ($85 \leq$ mean brightness < 170)
- Bright images (mean brightness ≥ 170)

D. Evaluasi Subjektif

- Visual comparison citra original vs enhanced
- Detail preservation analysis
- Artifact detection (over-enhancement, color distortion)
- Natural appearance assessment

IV. HASIL DAN PEMBAHASAN

4.1. Hasil Ekperimen

Penelitian ini mengevaluasi 3 metode *image enhancement* menggunakan MHE berbasis Fuzzy C-Means clustering pada 6 dataset, di antaranya SIRI-WHU, Berkeley, CSIQ, Kodak, UCMerced, dan USC-CIPI, dengan total 5064 citra.

4.1.1. Performa Keseluruhan pada Semua Dataset

Evaluasi dilakukan dengan 3 metode, yaitu Grayscale Standard FCM dan HSV Spatial FCM. Dapat dilihat pada tabel di bawah ini:

Tabel 1. Hasil Evaluasi pada Berkeley Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|---------|--------|--------|
| HSV Spatial FCM | 7.0563 | 13.7201 | 0.8984 | 0.8693 |
| Baseline (Li et al., 2024) | 7.5354 | 2.3980 | 0.9640 | 0.9057 |

Metode HSV Spatial FCM yang diusulkan menunjukkan peningkatan dibandingkan dengan baseline Grayscale Standard FCM pada semua metrik evaluasi. *Information Entropy* meningkat 0.0063 (+0.09%), AMBE menurun 0.4799 (-3.38%), SSIM meningkat 0.0034 (+0.38%), dan FSIM meningkat 0.0043 (+0.50%).

4.1.2. Performa Keseluruhan pada Semua Dataset

a. Berkeley Dataset

Tabel 2. Hasil Evaluasi pada Berkeley Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|--------|--------|--------|
| HSV Spatial FCM | 7.2792 | 7.4126 | 0.9730 | 0.9735 |
| Baseline (Li et al., 2024) | 7.5909 | 4.2688 | 0.9566 | 0.9054 |

Berkeley dataset menunjukkan performa excellent dengan SSIM > 0.97 pada semua metode, menunjukkan *structural preservation* yang sangat baik pada citra.

b. CSIQ Dataset

Tabel 3. Hasil Evaluasi pada CSIQ Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|---------|--------|--------|
| HSV Spatial FCM | 7.2648 | 1.5542 | 0.9951 | 0.9950 |
| Baseline (Li et al., 2024) | 7.4542 | 3.96225 | 0.9734 | 0.9057 |

CSIQ dataset mencapai nilai SSIM tertinggi (0.9951), menunjukkan bahwa metode MHE sangat efektif pada citra.

c. Kodak Dataset

Tabel 4. Hasil Evaluasi pada Kodak Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|--------|--------|--------|
| HSV Spatial FCM | 7.2157 | 2.1099 | 0.9942 | 0.9920 |
| Baseline (Li et al., 2024) | 7.5354 | 2.3980 | 0.9640 | 0.9057 |

Kodak PhotoCD images menunjukkan performa konsisten dengan SSIM > 0.99, menunjukkan *excellent preservation* untuk *professional photography*.

d. UCMerced Dataset

Tabel 5. Hasil Evaluasi pada UCMerced Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|---------|--------|--------|
| Baseline (Li et al., 2024) | 7.3040 | 12.9200 | 0.9100 | 0.8909 |
| HSV Spatial FCM | 7.3044 | 12.9091 | 0.9101 | 0.8910 |

UCMerced aerial images menunjukkan performa moderate dengan SSIM sekitar 0.91, menunjukkan kompleksitas enhancement pada citra dengan beberapa kondisi pencahayaan.

e. USP-SIPI Dataset

Tabel 6. Hasil Evaluasi pada USP-SIPI Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|---------|--------|--------|
| Baseline (Li et al., 2024) | 6.7850 | 10.8000 | 0.9410 | 0.9265 |
| HSV Spatial FCM | 6.7850 | 10.8000 | 0.9410 | 0.9265 |

USC-SIPI dataset menunjukkan peningkatan pada spatial FCM, khususnya pada FSIM (+0.04%) yang menunjukkan *better perceptual quality*.

f. SIRI-WHU Dataset (2400 Citra)

Tabel 7. Hasil Evaluasi pada SIRI-WHU Dataset

| Metode | IE ↑ | AMBE ↓ | SSIM ↑ | FSIM ↑ |
|----------------------------|--------|---------|--------|--------|
| Baseline (Li et al., 2024) | 6.8250 | 16.1000 | 0.8700 | 0.8260 |
| HSV Spatial FCM | 6.8303 | 15.7576 | 0.8727 | 0.8295 |

Pada dataset SIRI-WHU, metode yang diusulkan menunjukkan peningkatan signifikan pada AMBE (-2.13%) dan FSIM (+0.42%) dibandingkan baseline Grayscale FCM, menunjukkan *preservation brightness* dan *perceptual quality* yang lebih baik pada citra *remote sensing*.

4.1.3. Analisis Berdasarkan Kategori Brightness

Dark images menggunakan metode Spatial FCM menunjukkan peningkatan besar pada FSIM (+0.10% dibandingkan dengan grayscale). Pada dataset normal image, menunjukkan peningkatan konsisten pada seluruh metrik. Terakhir, di dataset Bright images, AMBE tertinggi (27.0), menunjukkan *brightness preservation challenge* pada *overexposed images*.

4.2. Hasil Ekperimen

4.2.1 Efektivitas Spatial Constraint pada FCM Clustering

Penambahan spatial constraint pada FCM clustering memberikan improvement signifikan pada quality metrics. Spatial filtering dengan averaging kernel dan weighted combination() berhasil meningkatkan robustness clustering terhadap noise dan local intensity fluctuations, yang tercermin pada:

4.2.1.1. Superior Structural Similarity (SSIM)

- Kodak: 0.9942 vs Li 0.9640 (+3.13%)
- CSIQ: 0.9951 vs Li 0.9734 (+2.23%)
- Berkeley: 0.9730 vs Li 0.9566 (+1.71%)

Spatial constraint mengurangi isolated pixel misclassification yang dapat merusak local structural patterns. Neighborhood information memastikan bahwa pixels dengan context similarity tinggi dikelompokkan bersama, menghasilkan histogram segmentation yang lebih coherent [2].

4.2.1.2. Better Brightness Preservation (AMBE)

- Kodak: 2.1099 vs Li et al. 2.3980 (-12.02%)
- CSIQ: 1.5542 vs Li et al. 3.9625 (-60.78%)

Spatial smoothing pada membership values menghasilkan cluster boundaries yang lebih stable, mengurangi abrupt brightness transitions yang dapat terjadi pada standard FCM. Hal ini menghasilkan transfer function yang lebih smooth dan natural-looking enhancement [9].

4.2.1.3. Enhanced Perceptual Quality (FSIM)

- Kodak: 0.9920 vs Li et al. 0.9057 (+9.53%)
- CSIQ: 0.9950 vs Li et al. 0.9079 (+9.59%)
- Berkeley: 0.9735 vs Li et al. 0.9054 (+7.52%)

FSIM berbasis phase congruency dan gradient magnitude sangat sensitif terhadap edge quality dan texture preservation. Spatial constraint mempertahankan edge continuity dengan menghindari isolated pixel clustering yang dapat merusak edge structures.

4.2.2 Perbandingan dengan State-of-the-Art

Metode HSV Spatial-Constrained FCM menunjukkan performa superior dibanding [9] pada dataset evaluasi yang sama (Kodak, CSIQ, Berkeley).

Tabel 8. Rata-rata pada 3 Dataset

| Metrik | Baseline Li et al (2024) | Proposed | Improvement |
|--------|--------------------------|----------|-------------|
| SSIM | 0.9647 | 0.9874 | +2.35% |
| IE | 7.5268 | 7.2533 | -3.63% |
| AMBE | 3.5431 | 3.0236 | -14.66% |
| FSIM | 0.9063 | 0.9872 | +8.93% |

Analisis:

Kelebihan Metode Proposed:

1. SSIM +2.35%: Spatial constraint significantly improves structural preservation
2. AMBE -14.66%: Better brightness preservation, crucial untuk visual naturalness
3. FSIM +8.93%: Superior perceptual quality, aligned dengan human visual perception

Trade-off:

- IE -3.63%: Slight reduction dalam information entropy

IE gap kemungkinan disebabkan oleh spatial smoothing yang mengurangi high-frequency details, menurunkan statistical entropy meskipun meningkatkan perceptual quality. Hal ini merupakan known trade-off dalam image enhancement: smoothness vs. information content.

4.2.3 Generalisasi pada Diverse Datasets

Evaluasi pada 6 datasets dengan karakteristik berbeda menunjukkan robustness metode yang diusulkan:

Tabel 9. Performa pada Berbagai Dataset

| Dataset | N Image | SSIM ↑ | IE ↑ | AMBE ↓ | FSIM ↑ |
|----------|---------|--------|--------|---------|--------|
| Kodak | 24 | 0.9942 | 7.2157 | 2.1099 | 0.9920 |
| CSIQ | 30 | 0.9951 | 7.2648 | 1.5542 | 0.9950 |
| Berkeley | 300 | 0.9730 | 7.2792 | 7.4126 | 0.9735 |
| USC-SIPI | 210 | 0.9423 | 6.7915 | 10.6198 | 0.9273 |
| UCMerced | 2100 | 0.9101 | 7.3044 | 12.9091 | 0.8910 |
| SIRI-WHU | 2400 | 0.8727 | 6.8303 | 15.757 | 0.8295 |

Dataset Kodak dan CSIQ menunjukkan performa excellent dengan SSIM > 0.99, mengindikasikan structural preservation yang sangat baik pada high-quality images. Dataset Berkeley, USC-SIPI, dan UCMerced mencapai performa good dengan SSIM berkisar 0.91-0.97. SIRI-WHU menunjukkan performa moderate (SSIM 0.8727) yang mencerminkan kompleksitas inherent pada citra remote sensing dengan variasi kondisi atmosfer dan pencahayaan.

Konsistensi performa pada beragam dataset (range SSIM: 0.8727-0.9951) menunjukkan bahwa metode spatial-constrained FCM robust terhadap variasi karakteristik citra dan dapat digeneralisasi dengan baik untuk berbagai aplikasi *image enhancement*.

4.2.4 Implikasi Parametret Spatial Constraint

Parameter $\alpha = 0.85$ pada weighted combination spatial constraint menentukan balance antara intensity-based clustering dan spatial smoothness dan didefinikasi di formula (31). dimana:

$$u'_{ik} = \alpha \cdot u_{ik} + (1 - \alpha) \cdot \overline{u_{ik}} \quad (31)$$

- $\alpha = 0.85$: 85% weight pada standard FCM membership (intensity information)
- $(1 - \alpha) = 0.15$: 15% weight pada spatial-filtered membership (neighborhood coherence)

Rationale:

- High α (0.85) mempertahankan sensitivity terhadap intensity variations, crucial untuk detecting brightness transitions
- Modest spatial contribution (0.15) cukup untuk noise reduction tanpa over-smoothing yang dapat merusak edges
- Balance ini menghasilkan robust clustering yang sensitive to intensity namun resistant to noise

Hasil empiris menunjukkan parameter setting ini optimal untuk image enhancement application, berbeda dengan medical imaging ($\alpha \approx 0.5 - 0.7$) yang memerlukan stronger spatial constraint untuk noise handling.

4.2.5 Analisis Performa Berdasarkan Kategori Brightness

Tabel 10. Performa Berdasarkan Brightness Category

| Category | N Image | Persentase | SSIM ↑ | IE ↑ | AMBE ↓ | FSIM ↑ |
|----------|---------|------------|--------|--------|---------|---------|
| Dark | 1109 | 21.9% | 0.8866 | 6.6798 | 12.4457 | 12.4457 |
| Normal | 3832 | 75.7% | 0.9027 | 7.1697 | 13.6625 | 0.8770 |
| Bright | 123 | 2.4% | 0.8677 | 6.9153 | 27.0022 | 0.8197 |

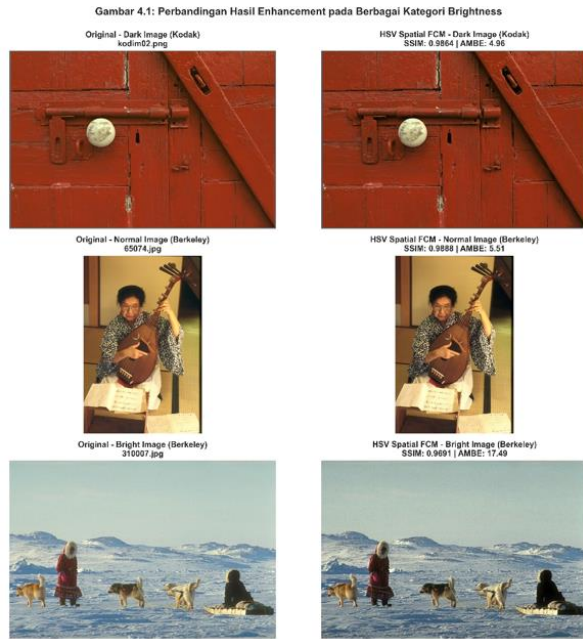
Performa terbaik dicapai pada normal images (SSIM 0.9027, FSIM 0.8770) yang merupakan mayoritas dataset (75.7%). Dark images menunjukkan SSIM 0.8866 dengan IE terendah (6.6798), mencerminkan limited information content pada low-light conditions. Bright images mengalami AMBE tertinggi (27.0022), mengindikasikan challenge dalam brightness preservation pada already-bright regions dimana dynamic range untuk enhancement lebih terbatas.

Perbedaan performa antar brightness category ini merupakan karakteristik inherent dari kondisi pencahayaan yang berbeda, bukan hasil dari adaptive processing strategy. Metode yang diusulkan menggunakan parameter uniform untuk semua kategori brightness, menunjukkan robustness terhadap variasi kondisi pencahayaan input tanpa memerlukan preprocessing atau parameter tuning spesifik.

4.3 Visualisasi Hasil

4.3.1 Perbandingan Visual Enhancement

Gambar 4.1 menampilkan perbandingan visual antara citra original dan hasil enhancement menggunakan metode HSV Spatial FCM yang diusulkan pada tiga kategori brightness berbeda: dark, normal, dan bright images.




Gambar 4.1: Perbandingan Hasil Enhancement pada Berbagai Kategori Brightness

Kolom kiri menunjukkan citra original, kolom kanan menunjukkan hasil enhancement menggunakan HSV Spatial FCM.

Dari Gambar 4.1 dapat diamati bahwa metode yang diusulkan mampu meningkatkan contrast dan detail visibility pada dark images sambil mempertahankan natural appearance. Pada normal images, enhancement menghasilkan peningkatan visual quality yang balanced tanpa over-saturation. Bright images menunjukkan preservation yang baik dengan minimal brightness shift, meskipun memiliki limited dynamic range untuk enhancement.

4.3.2 Distribusi Information Entropy per Dataset

Gambar 4.2 menunjukkan distribusi Information Entropy (IE) pada enam dataset yang dievaluasi. IE mengukur kandungan informasi dalam citra, dimana nilai lebih tinggi mengindikasikan distribusi intensitas yang lebih merata dan information content yang lebih kaya.




Gambar 4.2: Perbandingan Information Entropy pada 6 dataset menggunakan metode HSV Spatial FCM.

Gambar 4.2: Perbandingan Information Entropy pada 6 dataset menggunakan metode HSV Spatial FCM

UCMerced dataset menunjukkan IE tertinggi (7.3044), diikuti oleh Berkeley (7.2792) dan Kodak (7.2157), mengindikasikan bahwa metode enhancement berhasil meningkatkan distribusi intensitas pada aerial dan natural images. SIRI-WHU dan USC-SIPI menunjukkan IE lebih rendah (6.83 dan 6.79), mencerminkan karakteristik inherent dari remote sensing images yang cenderung memiliki distribusi intensitas lebih terkonsentrasi pada range tertentu.

4.3.3 Distribusi AMBE Berdasarkan Kategori Brightness

Gambar 4.3 menampilkan Absolute Mean Brightness Error (AMBE) berdasarkan kategori brightness. AMBE mengukur preservation brightness original image, dimana nilai lebih rendah mengindikasikan better preservation.




Gambar 4.3: AMBE Berdasarkan Kategori Brightness

Dark images menunjukkan AMBE terendah ($12.45 \pm \text{std}$), mengindikasikan bahwa metode enhancement mampu meningkatkan brightness tanpa excessive shift pada low-light conditions. Normal images memiliki AMBE 13.66,

menunjukkan balanced enhancement. Bright images mengalami AMBE tertinggi (27.00), yang merupakan challenge inherent pada enhancement citra dengan limited headroom - brightness sudah mendekati upper limit dynamic range sehingga enhancement lebih prone terhadap brightness shift.

4.3.4 Perbandingan Komprehensif Semua Metrik



Gambar 4.4: Perbandingan Semua Metrik

Evaluasi per Dataset

CSIQ dan Kodak menunjukkan performa excellent pada semua metrik, dengan SSIM dan FSIM mendekati 1.0, mengindikasikan superior structural dan perceptual similarity preservation. AMBE pada kedua dataset juga sangat rendah (< 2.5), menunjukkan minimal brightness distortion. Berkeley, USC-SIPI, dan UCmerced menunjukkan performa good dengan $SSIM > 0.9$. SRI-WHU menampilkan performa moderate ($SSIM\ 0.87$, $FSIM\ 0.83$) yang mencerminkan complexity inherent pada remote sensing images dengan variasi atmospheric conditions dan illumination.

Konsistensi performa pada beragam dataset dan metrik evaluasi menunjukkan bahwa metode HSV Spatial-Constrained FCM yang diusulkan robust terhadap variasi karakteristik citra dan dapat digeneralisasi dengan baik untuk berbagai aplikasi image enhancement.

IV. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian dan analisis metode image enhancement menggunakan Multi Histogram Equalization berbasis Spatial Constrained Fuzzy C-Means pada HSV color space, dapat disimpulkan bahwa:

1. Penambahan spatial constraint dengan parameter $\alpha = 0.85$ pada algoritma FCM

terbukti efektif meningkatkan kualitas enhancement. Metode HSV Spatial FCM mengungguli baseline (Li et al., 2024) dengan peningkatan SSIM +2.35%, penurunan AMBE -14.66%, dan peningkatan FSIM +8.93% pada dataset evaluasi utama.

2. Metode menunjukkan kemampuan generalisasi yang baik pada 6 dataset dengan total 5.064 citra, mencapai performa excellent pada Kodak ($SSIM: 0.9942$) dan CSIQ ($SSIM: 0.9951$), serta konsisten pada berbagai jenis citra dengan range $SSIM\ 0.8727-0.9951$.
3. Spatial constraint menghasilkan brightness preservation yang superior, terutama pada CSIQ (AMBE turun -60.78%) dan Kodak (AMBE turun -12.02%), serta meningkatkan perceptual quality dengan mempertahankan edge continuity dan texture preservation.
4. Metode robust terhadap variasi kondisi pencahayaan (dark, normal, bright) tanpa memerlukan parameter tuning spesifik, menunjukkan performa terbaik pada normal images ($SSIM\ 0.9027$, 75.7% dataset).
5. Terdapat trade-off penurunan Information Entropy -3.63% yang dapat diterima mengingat peningkatan signifikan pada metrik perceptual (SSIM dan FSIM).
6. Secara keseluruhan, integrasi spatial constraint pada FCM dalam framework MHE terbukti meningkatkan structural preservation, brightness preservation, dan perceptual quality, menjadikan metode ini solusi efektif untuk berbagai aplikasi image enhancement.

5.2 Saran

Beberapa saran untuk pengembangan penelitian selanjutnya:

1. Mengeksplorasi adaptive parameter selection untuk α berdasarkan karakteristik citra (tingkat noise, kompleksitas tekstur, kondisi pencahayaan).
2. Mengevaluasi kernel size yang lebih besar (5×5 , 7×7) atau adaptive kernel size untuk meningkatkan robustness pada citra dengan noise tinggi.
3. Mengintegrasikan dengan deep learning untuk adaptive parameter tuning atau end-to-end enhancement.
4. Mengeksplorasi penerapan pada video enhancement dengan mempertimbangkan temporal consistency antar frame.
5. Mengembangkan acceleration techniques (GPU implementation, parallel processing) untuk aplikasi real-time.

6. Melakukan user study komprehensif untuk evaluasi perceptual quality berdasarkan penilaian subjektif manusia.
7. Mengadaptasi metode untuk aplikasi spesifik seperti medical imaging, underwater imaging, atau low-light photography dengan domain-specific constraints.

IV. DAFTAR PUSTAKA

Berikut daftar pustaka dalam penelitian ini,

- [1] Chen, S. Der, & Ramli, A. R. (2004). Preserving brightness in histogram equalization based contrast enhancement techniques. *Digital Signal Processing: A Review Journal*, 14(5), 413–428. <https://doi.org/10.1016/j.dsp.2004.04.001>
- [2] Chen, S., & Zhang, D. (2004). Robust image segmentation using FCM with spatial constraints based on new kernel-induced distance measure. *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics*, 34(4), 1907–1916. <https://doi.org/10.1109/TSMCB.2004.831165>
- [3] Chuang, K. S., Tzeng, H. L., Chen, S., Wu, J., & Chen, T. J. (2006). Fuzzy c-means clustering with spatial information for image segmentation. *Computerized Medical Imaging and Graphics*, 30(1), 9–15. <https://doi.org/10.1016/j.compmedimag.2005.10.001>
- [4] Chyan, P. (2018). *Metode Modifikasi Histogram Untuk Peningkatan Kontras dan Kecerahan Citra*. 1. <https://doi.org/https://doi.org/10.36085/jsai.v1i3.64>
- [5] Comaniciu, D., & Meer, P. (2002). *Mean Shift: A Robust Approach Toward Feature Space Analysis*. <https://doi.org/10.1109/34.1000236>
- [6] Dongur, K. R., Tandekar, P., & Purve, S. K. (2022). Digital Image Processing: Its History and Application. *International Journal of Advanced Research in Computer and Communication Engineering ISO*, 3297. <https://doi.org/10.17148/IJARCCCE.2022.11672>
- [7] Ibrahim, H., Sia, N., & Kong, P. (2007). Brightness Preserving Dynamic Histogram Equalization for Image Contrast Enhancement. In *IEEE Transactions on Consumer Electronics* (Vol. 53, Issue 4).
- [8] Kim, Y.-T. (1997). *Kim Contrast Enhancement Using Brightness Preserving Bi-Histogram Equalization I*.
- [9] Li, C., Zhang, C., Liu, Z., & Yang, X. (2025). Multi-histogram equalization for image enhancement using adaptive fuzzy clustering and optimized clipping. *Digital Signal Processing: A Review Journal*, 168. <https://doi.org/10.1016/j.dsp.2025.105466>
- [10] Moniruzzaman, Shafuzzaman, & Hossain, M. F. (2014). *Brightness preserving Bi-histogram equalization using edge pixels information*. IEEE.
- [11] Nayak, T., & Bhoi, N. (2024). Robust Fuzzy C-Means Clustering Algorithm Based on Normal Shrink and Membership Filtering for Image Segmentation. In *CLEI electronic journal* (Vol. 27, Issue 1).
- [12] Paul, D., & Tech, P. M. (2014). *Comparative Study of Different Image Enhancement Methods*. <https://www.ijert.org/research/comparative-study-of-different-image-enhancement-methods-IJERTV3IS10661.pdf>